Инвестиции в компании-стартапы

В нашем распоряжении база данных, которая хранит информацию о венчурных фондах и инвестициях в компании-стартапы. Эта база данных основана на датасете Startup Investments, опубликованном на популярной платформе для соревнований по исследованию данных Kaggle.

Цель проекта: проанализировать данные о фондах и инвестициях и с помощью различных SQL-запросов к базе данных. Продемонстрировать изученные операторы, функции и методы работы с базой данных.

Описание проекта:

Познакомимся с важными понятиями, которые встретятся в работе с базой данных:

Венчурные фонды — это финансовые организации, которые могут позволить себе высокий риск и инвестировать в компании с инновационной бизнес-идеей или разработанной новой технологией, то есть в *стартапы*. Цель венчурных фондов — в будущем получить значительную прибыль, которая в разы превысит размер их трат на инвестиции в компанию. Если стартап подорожает, венчурный фонд может получить долю в компании или фиксированный процент от её выручки.

Чтобы процесс финансирования стал менее рискованным, его делят на стадии — *раунды*. Тот или иной раунд зависит от того, какого уровня развития достигла компания.

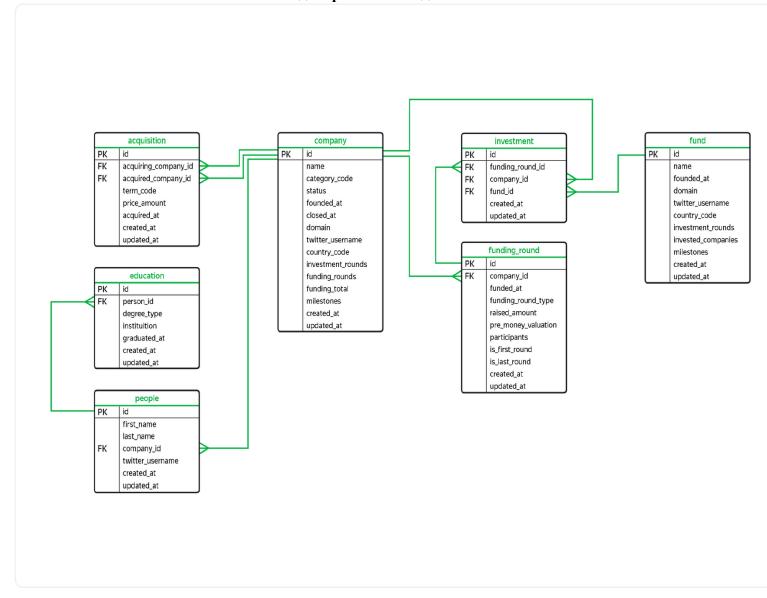
Первые этапы — *предпосевной* и *посевной* раунды. Предпосевной раунд предполагает, что компания как таковая ещё не создана и находится в стадии замысла. Следующий — посевной — раунд знаменует рост проекта: создатели компании разрабатывают бизнес-модель и привлекают инвесторов.

Если компании требуется ментор или наставник — она привлекает *бизнес-ангела*. Бизнес-ангелы — инвесторы, которые помимо финансовой поддержки предлагают экспертную помощь. Такой раунд называют *ангельским*.

Когда стартап становится компанией с проверенной бизнес-моделью и начинает зарабатывать самостоятельно, предложений инвесторов становится больше. Это раунд A, а за ним следуют и другие: B, C, D — на этих этапах компания активно развивается и готовится к IPO.

Иногда выделяют *венчурный раунд* — финансирование, которое могло поступить от венчурного фонда на любом этапе: начальном или более позднем.

ER-диаграмма базы данных



Ознакомимся с данными, которые хранят таблицы:

Acquisition

Содержит информацию о покупках одних компаний другими:

- первичный ключ id идентификатор или уникальный номер покупки;
- внешний ключ acquiring_company_id ссылается на таблицу company идентификатор компании-покупателя, то есть той, что покупает другую компанию;
- внешний ключ acquired_company_id ссылается на таблицу company идентификатор компании, которую покупают;
- term_code способ оплаты сделки:
 - о cash наличными;
 - о stock акциями компании;
 - \circ cash_and_stock смешанный тип оплаты: наличные и акции.
- ullet price_amount сумма покупки в долларах;
- acquired_at дата совершения сделки;
- created_at дата и время создания записи в таблице;
- updated_at дата и время обновления записи в таблице.

Company

Содержит информацию о компаниях-стартапах:

- первичный ключ id идентификатор, или уникальный номер компании;
- name название компании;
- category_code категория деятельности компании, например:
 - о news специализируется на работе с новостями;
 - o social специализируется на социальной работе.
- status статус компании:
 - о acquired приобретена;
 - o operating действует;
 - o іро вышла на IPO;
 - o closed перестала существовать.
- founded_at дата основания компании;
- closed at дата закрытия компании, которую указывают в том случае, если компании больше не существует;
- domain домен сайта компании;
- twitter username название профиля компании в твиттере;
- country_code код страны, например, USA для США, GBR для Великобритании;
- investment rounds число раундов, в которых компания участвовала как инвестор;
- funding_rounds число раундов, в которых компания привлекала инвестиции;
- funding_total сумма привлечённых инвестиций в долларах;
- milestones количество важных этапов в истории компании;
- created at дата и время создания записи в таблице;
- updated_at дата и время обновления записи в таблице.

Education

Хранит информацию об уровне образования сотрудников компаний:

- первичный ключ id уникальный номер записи с информацией об образовании;
- внешний ключ person_id ссылается на таблицу people идентификатор человека, информация о котором представлена в записи;
- degree_type учебная степень, например:
 - о ва Bachelor of Arts бакалавр гуманитарных наук;
 - о мs Master of Science магистр естественных наук.
- instituition учебное заведение, название университета;
- graduated_at дата завершения обучения, выпуска;
- created_at дата и время создания записи в таблице;
- updated_at дата и время обновления записи в таблице.

Fund

Хранит информацию о венчурных фондах:

- первичный ключ id уникальный номер венчурного фонда;
- пате название венчурного фонда;
- founded_at дата основания фонда;
- domain домен сайта фонда;
- twitter_username профиль фонда в твиттере;
- country_code код страны фонда;
- investment_rounds число инвестиционных раундов, в которых фонд принимал участие;
- invested_companies число компаний, в которые инвестировал фонд;
- milestones количество важных этапов в истории фонда;
- created_at дата и время создания записи в таблице;
- updated_at дата и время обновления записи в таблице.

Funding_round

Содержит информацию о раундах инвестиций:

- первичный ключ id уникальный номер инвестиционного раунда;
- внешний ключ company_id ссылается на таблицу company уникальный номер компании, участвовавшей в инвестиционном раунде;
- funded_at дата проведения раунда;
- funding_round_type тип инвестиционного раунда, например:
 - о venture венчурный раунд;
 - о angel ангельский раунд;
 - о series_a раунд А.
- raised amount сумма инвестиций, которую привлекла компания в этом раунде в долларах;
- pre_money_valuation предварительная, проведённая до инвестиций оценка стоимости компании в долларах;
- participants количество участников инвестиционного раунда;
- is first round является ли этот раунд первым для компании;
- is_last_round является ли этот раунд последним для компании;
- created_at дата и время создания записи в таблице;
- updated_at дата и время обновления записи в таблице.

Investment

Содержит информацию об инвестициях венчурных фондов в компании-стартапы:

- первичный ключ id уникальный номер инвестиции;
- внешний ключ funding round_id ссылается на таблицу funding round уникальный номер раунда инвестиции;
- внешний ключ company_id ссылается на таблицу company уникальный номер компании-стартапа, в которую инвестируют;
- внешний ключ fund_id ссылается на таблицу fund уникальный номер фонда, инвестирующего в компаниюстартап;
- created_at дата и время создания записи в таблице;
- updated_at дата и время обновления записи в таблице.

People

Содержит информацию о сотрудниках компаний-стартапов:

- первичный ключ id уникальный номер сотрудника;
- first_name имя сотрудника;
- last_name фамилия сотрудника;
- внешний ключ company id ссылается на таблицу company уникальный номер компании-стартапа;
- twitter_username профиль сотрудника в твиттере;
- created_at дата и время создания записи в таблице;
- updated_at дата и время обновления записи в таблице.

Исследуем рынок венчурных фондов и инвестиций в компании-стартапы с помощью запросов к базе данных:

1. Посчитаем, сколько компаний закрылось:
SELECT COUNT(id)
FROM company
WHERE status = 'closed'
соunt 2584
2. Отобразим количество привлечённых средств для новостных компаний США. Отсортируем таблицу по убыванию суммы привлечённых инвестиций в долларах. Ограничим таблицу 5 строками: SELECT SUM(funding_total) FROM company WHERE category_code = 'news' AND country_code = 'USA' GROUP BY id ORDER BY SUM(funding_total) DESC LIMIT 5
Результат
sum
6.22553e+08
2.5e+08
1.605e+08
1.28e+08
1.265e+08

3. Найдем общую сумму сделок по покупке одних компаний другими в долларах. Отберем сделки, которые осуществлялись только за наличные с 2011 по 2013 год включительно:

```
SELECT SUM(price_amount)
FROM acquisition
WHERE term_code = 'cash' AND
EXTRACT(YEAR FROM acquired_at) BETWEEN 2011 AND 2013
```

Результат

sum 1.37762e+11 4.Отобразим имя, фамилию и названия аккаунтов людей в твиттере, у которых названия аккаунтов начинаются на 'Silver':

SELECT first_name,
last_name,
twitter_username

FROM people

WHERE twitter_username LIKE 'Silver%'

Результат

first_name	last_name	twitter_username
Rebecca	Silver	SilverRebecca
Silver	Teede	SilverMatrixx
Mattias	Guilotte	Silverreven

5. Выведем всю информацию о людях, у которых названия аккаунтов в твиттере содержат подстроку 'money', а фамилия начинается на 'к':

SELECT *

FROM people

WHERE twitter_username LIKE '%money%' AND

last_name LIKE 'K%'

Результат

id	first_name	last_name	company_id	twitter_username	created_at	updated_at
63081	Gregory	Kim		gmoney75	2010-07-13 03:46:28	2011-12-12 22:01:34

6. Для каждой страны отобразим общую сумму привлечённых инвестиций, которые получили компании, зарегистрированные в этой стране. Ограничим таблицу 5 странами:

SELECT country_code, SUM(funding_total) FROM company GROUP BY country_code ORDER BY SUM(funding_total) DESC LIMIT 5

country_code	sum
USA	3.10588e+11
GBR	1.77056e+10
CHN	1.06897e+10
CAN	9.86636e+09
IND	6.14141e+09

7. Составим таблицу, в которую войдёт дата проведения раунда, а также минимальное и максимальное значения суммы инвестиций, привлечённых в эту дату. Оставим в итоговой таблице только те записи, в которых минимальное значение суммы инвестиций не равно нулю и не равно максимальному значению. Ограничим таблицу 10 строками:

```
SELECT funded_at,

MIN(raised_amount),

MAX(raised_amount)

FROM funding_round

GROUP BY funded_at

HAVING MIN(raised_amount) <> 0 AND

MIN(raised_amount) <> MAX(raised_amount)

LIMIT 10
```

Результат

Результат		
funded_at	min	max
2012-08-22	40000	7.5e+07
2010-07-25	3.27825e+06	9e+06
2002-03-01	2.84418e+06	8.95915e+06
2010-10-11	28000	2e+08
2007-01-18	5.5e+06	2.3e+07
2007-02-27	1.29e+06	3.6e+07
2006-01-05	8.9e+06	2.65e+07
2011-10-31	35000	2.5e+07
2012-10-27	500000	9.3e+06
2007-08-16	2.51989e+06	9e+06

8. Создадим поле с категориями:

- Для фондов, инвестирующих в 100 и более компаний, назначим категорию high_activity;
- Для фондов, инвестирующих в 20 и более компаний до 100 middle_activity;
- Если количество инвестируемых компаний фонда не достигает 20 low_activity.

Отобразим все поля таблицы fund и новое поле с категориями:

```
SELECT *, CASE

WHEN invested_companies > 100 THEN 'high_activity'

WHEN invested_companies BETWEEN 20 AND 100 THEN 'middle_activity'

WHEN invested_companies < 20 THEN 'low_activity'

END AS activity

FROM fund
```

activity	id	name	founded_at	domain	coun try_ code	investment_ rounds	invested_ companies	mi les to ne s
high_ activity	1	Greylock Partners	1965-01-01	greylock.com	USA	307	196	0
middle_ activity	10	Mission Ventures	1996-01-01	missionventures .com	USA	58	33	0
low_ activity	100	Kapor Enterprises		kei.com	USA	2	1	0
low_ activity	1000	Speed Ventures				0	0	1
low_ activity	10001	Salem Partners	1997-01-01	salempartners.	USA	1	1	0
low_ activity	10002	3T Capital		3tcapital.	FRA	3	3	0
low_ activity	10003	Merieux Developpe ment	2009-01-01	merieux- developpement. com	FRA	2	2	0
low_ activity	10004	Aquasourca		aquasourca.com	FRA	1	1	0

9. Посчитаем для каждой из категорий округлённое до ближайшего целого числа среднее количество инвестиционных раундов, в которых фонд принимал участие. Выведем категории и среднее число инвестиционных раундов. Отсортируем таблицу по возрастанию среднего:

```
SELECT CASE
```

```
WHEN invested_companies>=100 THEN 'high_activity'
WHEN invested_companies>=20 THEN 'middle_activity'
ELSE 'low_activity'
END AS activity,
ROUND(AVG(investment_rounds)) AS avg_investment_rounds
```

FROM fund

GROUP BY activity

ORDER BY avg_investment_rounds

Результат

activity	avg_investment_rounds
low_activity	2
middle_activity	51
high_activity	252

10. Проанализируем, в каких странах находятся фонды, которые чаще всего инвестируют в стартапы. Для каждой страны посчитаем минимальное, максимальное и среднее число компаний, в которые инвестировали фонды этой страны, основанные с 2010 по 2012 год включительно. Исключим страны с фондами, у которых минимальное число компаний, получивших инвестиции, равно нулю.

Выгрузим десять самых активных стран-инвесторов: отсортируем таблицу по среднему количеству компаний от большего к меньшему. Затем добавим сортировку по коду страны в лексикографическом порядке. Ограничим таблицу 5 странами:

```
SELECT country_code,
    MIN(invested_companies),
    MAX(invested_companies),
    AVG(invested_companies)

FROM fund
WHERE EXTRACT(YEAR FROM founded_at) BETWEEN 2010 AND 2012
GROUP BY country_code
HAVING MIN(invested_companies) <> 0
ORDER BY AVG(invested_companies) DESC, country_code
LIMIT 5
```

country_code	min	max	avg
BGR	25	35	30
CHL	29	29	29
UKR	8	10	9
LTU	5	5	5
IRL	4	5	4.5

11. Отобразим имя и фамилию всех сотрудников стартапов. Добавим поле с названием учебного заведения, которое окончил сотрудник, если эта информация известна. Ограничим таблицу 5 строками:

LIMIT 5

Результат

first_name	last_name	instituition		
John	Green	Washington University, St. Louis		
John	Green	Boston University		
David	Peters	Rice University		
Dan	Birdwhistell	University of Cambridge		
Gal	Cohen	Tel Aviv University		

12. Для каждой компании найдём количество учебных заведений, которые окончили её сотрудники. Выведем название компании и число уникальных названий учебных заведений. Составим топ-5 компаний по количеству университетов:

```
SELECT c.name,

COUNT(DISTINCT e.instituition)

FROM company c

LEFT JOIN people p ON c.id = p.company_id

INNER JOIN education e ON p.id = e.person_id

GROUP BY c.name

ORDER BY COUNT(DISTINCT e.instituition) DESC

LIMIT 5
```

name	count
Google	167
Yahoo!	115
Microsoft	111
Knight Foundation	74
Comcast	66

13. Составим список с уникальными названиями закрытых компаний, для которых первый раунд финансирования оказался последним:

1 вариант:

```
SELECT DISTINCT name
FROM company
WHERE id IN (SELECT company_id
             FROM funding_round fr
             INNER JOIN company c ON fr.company_id = c.id
             WHERE fr.is_first_round = 1 AND
                  fr.is_last_round = 1 AND
                   status = 'closed')
```

2 вариант:

```
SELECT DISTINCT name
FROM company {\sf c}
INNER JOIN funding_round fr ON fr.company_id = c.id
WHERE fr.is_first_round = 1 AND
      fr.is_last_round = 1 AND
```

Результат
name
10BestThings
11i Solutions
169 ST.
1bib
1Cast
1DayMakeover
25eight
27 Perry
2Win-Solutions
3Touch

status = 'closed'

14. Составим список уникальных номеров сотрудников, которые работают в компаниях, отобранных в предыдущем задании. Ограничим таблицу 5 строками:

Результат	
id	
62	
97	
98	
225	
226	

15. Составим таблицу, куда войдут уникальные пары с номерами сотрудников из предыдущей задачи и учебным заведением, которое окончил сотрудник. Ограничим таблицу 5 строками:

гезультат	
id	instituition
349	AKI
349	ArtEZ Hogeschool voor de Kunsten
349	Rijks Akademie
699	Imperial College
779	Harvard University

16. Посчитаем количество учебных заведений для каждого сотрудника из предыдущего задания. Ограничим таблицу 5 строками:

Результат

CSYMBIAI	
id	count
8666	2
9397	2
6087	1
9643	2
73469	1

17. Дополним предыдущий запрос и выведем среднее число учебных заведений (всех, не только уникальных), которые окончили сотрудники разных компаний:

SELECT AVG(a.number_of_instituitions) AS avg_number_of_instituitions FROM a

avg_number_of_instituitions			
1.41509			

18. Выведем среднее число учебных заведений (всех, не только уникальных), которые окончили сотрудники Facebook:

SELECT AVG(a.number_of_instituitions) AS avg_facebook
FROM a

Результат

avg_facebook
1.51111

19. Составим таблицу из полей:

- name_of_fund название фонда;
- name_of_company название компании;
- amount сумма инвестиций, которую привлекла компания в раунде.

В таблицу войдут данные о компаниях, в истории которых было больше шести важных этапов, а раунды финансирования проходили с 2012 по 2013 год включительно. Ограничим таблицу 5 строками:

LIMIT 5

name_of_fund	name_of_company	amount
CADA	O W	2.50112 . 07
SAP Ventures	OpenX	2.50112e+07
G V	O V	2.50112 .07
Samsung Ventures	OpenX	2.50112e+07
Index Ventures	OpenX	2.50112e+07
Presidio Ventures	OpenX	2.50112e+07
DAG Ventures	Gigya	2.5e+07

20. Выгрузим таблицу, в которой будут такие поля:

- название компании-покупателя;
- сумма сделки;
- название компании, которую купили;
- сумма инвестиций, вложенных в купленную компанию;
- доля, которая отображает, во сколько раз сумма покупки превысила сумму вложенных в компанию инвестиций, округлённая до ближайшего целого числа.

При этом не будем учитывать те сделки, в которых сумма покупки равна нулю. Если сумма инвестиций в компанию равна нулю, также исключим такую компанию из таблицы.

Отсортируем таблицу по сумме сделки от большей к меньшей, а затем по названию купленной компании в лексикографическом порядке. Ограничим таблицу 10 строками:

acquiring_company	price_amount	acquired_company	funding_total	share
Microsoft	8.5e+09	Skype	7.6805e+07	111
Scout Labs	4.9e+09	Varian Semiconductor Equipment Associates	4.8e+06	1021
Broadcom	3.7e+09	Aeluros	7.97e+06	464
Broadcom	3.7e+09	NetLogic Microsystems	1.88527e+08	20
Level 3 Communications	3e+09	Global Crossing	4.1e+07	73
Yahoo!	2.87e+09	GeoCities	4e+07	72
eBay	2.6e+09	Skype	7.6805e+07	34
Salesforce	2.5e+09	ExactTarget	2.3821e+08	10
Johnson & Johnson	2.3e+09	Crucell	4.43e+08	5
IAC	1.85e+09	Ask.com	2.5e+07	74

21. Выгрузим таблицу, в которую войдут названия компаний из категории social, получившие финансирование с 2010 по 2013 год включительно. Сумма инвестиций не должна быть равна нулю. Выведем также номер месяца, в котором проходил раунд финансирования. Ограничим таблицу 5 строками:

Результат

Результат company_name	month
Klout	1
WorkSimple	3
HengZhi	1
Twitter	1
SocialGO	1
ThisNext	1
Tagged	1
LikeMe.Net	2
Busuu	10
NetBase	3
Solutions	

22. Отберём данные по месяцам с 2010 по 2013 год, когда проходили инвестиционные раунды. В итоговой таблице должны быть следующие поля:

- номер месяца, в котором проходили раунды;
- количество уникальных названий фондов из США, которые инвестировали в этом месяце;
- количество компаний, купленных за этот месяц;
- общая сумма сделок по покупкам в этом месяце.

Результат

month	fund_amount	company_amount	total_price
1	815	600	2.71083e+10
2	637	418	4.13903e+10
3	695	458	5.95016e+10
4	718	411	3.03837e+10
5	695	532	8.60122e+10
6	785	525	5.20883e+10
7	803	488	4.98541e+10
8	726	454	7.77093e+10
9	793	491	6.97409e+10
10	764	473	4.85567e+10
11	661	414	4.79386e+10
12	590	433	3.74251e+10

23. Составим сводную таблицу и выведем среднюю сумму инвестиций для стран, в которых есть стартапы, зарегистрированные в 2011, 2012 и 2013 годах. Отсортируем таблицу по среднему значению инвестиций за 2011 год от большего к меньшему. Ограничим таблицу 20 странами:

```
WITH a AS (SELECT country_code,
           AVG(funding_total) AS avg_2011
           FROM company
           WHERE EXTRACT(YEAR FROM founded_at) = 2011
           GROUP BY country_code),
     b AS (SELECT country_code,
           AVG(funding_total) AS avg_2012
           FROM company
           WHERE EXTRACT(YEAR FROM founded_at) = 2012
           GROUP BY country_code),
    c AS (SELECT country_code,
          AVG(funding_total) AS avg_2013
          FROM company
          WHERE EXTRACT(YEAR FROM founded_at) = 2013
          GROUP BY country_code)
 SELECT a.country_code,
        a.avg_2011,
        b.avg_2012,
        c.avg_2013
FROM a
INNER JOIN b ON a.country_code = b.country_code
INNER JOIN c ON a.country_code = c.country_code
```

Результат	зультат				
country_code	avg_2011	avg_2012	avg_2013		
PER	4e+06	41000	25000		
USA	2.24396e+06	1.20671e+06	1.09336e+06		
НКС	2.18078e+06	226227	0		
PHL	1.75e+06	4218.75	2500		
ARE	1.718e+06	197222	35333.3		
JPN	1.66431e+06	674720	50000		
AUT	1.5342e+06	147806	85773.3		
BRA	1.38007e+06	240639	67944.4		
DEU	1.1288e+06	1.32915e+06	66612.7		
ISR	1.03076e+06	1.27121e+06	294022		
PST	1e+06	0	0		
FRA	977874	291227	642083		
CHN	975918	611436	1e+06		
AUS	963088	192949	26313.7		
ZAF	962000	576000	0		
IRL	929919	199051	36683.8		
IND	763426	230497	21814.4		
RUS	725870	420155	132500		
GBR	706840	357222	273237		
TWN	657143	110000	0		